

# Resumen de calidad de dato

## Hallazgos principales

- **Columnas de aeropuerto faltantes:** origin\_code, origin\_name, origin\_city, origin\_state, dest\_code, dest\_name, dest\_city, dest\_state están completamente vacías (100 000 filas).
- **Retrasos de llegada y total con nulos:** arr\_delay y total\_delay tienen 606 valores nulos.
- **Indicadores de retraso:** DepDel15, DepDel30, DepDel60 existen y no tienen nulos; DepDel15 no discrimina porque el mínimo de dep\_delay es 15.
- **Outliers significativos:** 722 vuelos con dep\_delay > 360 min y 711 con arr\_delay > 360 min.
- **Integridad de claves y duplicados:** no hay duplicados (0) y las claves (airline\_id, origin\_airport\_id, destination\_airport\_id, fecha\_id) están completas.
- **Distance:** no hay distancias cero (Distance == 0: 0).

Se detectaron 606 nulos en arr\_delay/total\_delay y ~720 outliers en retrasos > 6 horas; las medias están afectadas por estos extremos.

Se crearán y reportarán DepDel30 y DepDel60; se priorizará el uso de medianas e IQR y se extraerán outliers para investigación operativa.

## Acciones recomendadas (priorizadas)

1. **Rellenar datos de aeropuerto:** mapear origin\_airport\_id y destination\_airport\_id a dim\_airport para recuperar airport\_code y airport\_name y reemplazar las columnas vacías.
2. **Revisar nulos en arr\_delay/total\_delay:** inspeccionar flight\_status para las 606 filas nulas y decidir imputación o exclusión según caso (cancelled/diverted vs error ETL).
3. **Investigar outliers > 360 min:** extraer top outliers, revisar causas (flight\_status, demoras por causa operativa o meteorológica) y documentar si deben excluirse de estadísticas agregadas.
4. **Usar métricas robustas:** reportar mediana y percentiles por aerolínea/aeropuerto; usar DepDel30 y DepDel60 para frecuencia informativa.
5. **Documentar transformaciones:** anotar en el diccionario las imputaciones, umbrales usados y criterios de exclusión.

## KPIs sugeridos para reportes de calidad y operación

- % vuelos  $\geq 30$  min (pct\_del30) y % vuelos  $\geq 60$  min (pct\_del60) por aerolínea y aeropuerto.
- Mediana dep\_delay por aerolínea y por aerolínea $\times$ origen.
- Número de outliers  $> 360$  min por aerolínea.
- % filas con arr\_delay nulo y su relación con flight\_status.